

Character-level Convolutional Neural Networksにおける Wildcard Trainingの基礎検討

北田 俊輔, 彌富 仁
法政大学 理工学部 応用情報工学科
shunsuke.kitada.8y@stu.hosei.ac.jp



1. Background


日本語における文字の「表意性」と言語処理

→ 日本語の「文字」の数は英語に比べて膨大

- ◆ 形状的特徴を利用した文字表現の獲得 (Image-based character embedding)


→ 多種多様な新語や造語に対して正確に形態素解析を行うことは困難

- ◆ 単語レベルではなく, 文字レベルで処理を行う (Character-level convolutional neural networks + Wildcard training)



吾輩は猫である。名前はまだ無い。

- 形状的特徴を利用した文字のベクトル化
- 形態素解析・単語分割が不要
- Wildcard trainingによるData augmentation



Wildcard training (WT)

- 学習時に入力の2割程度を零ベクトルとすることで, 任意の文字を「Wildcard」として振る舞うことを期待
- 形態素解析等を前提としないData augmentationが可能
- 汎化性能の大幅な向上が確認されている

吾*は猫である。
名前は*だ無い。

- Wildcard trainingにおけるWildcard率は0.2で固定されている
- 日本語以外の言語に対して効果が確認されていない


より効果的な Wildcard trainingについて模索
日本語以外の言語に対しての効果の実証

2. Method

- Wildcard trainingにおけるWildcard率の検討
 - 各データセットに対してWildcard率を0.1~0.6に固定する
 - Wildcard率をイテレーション毎0.1~0.6の範囲で変化させる [2]
 - 線形的に上昇・降下 (Linear up/down) させる
 - 指数的に上昇・降下 (Exponential up/down) させる

本実験で用いたモデルのアーキテクチャと学習方法

- CAEを用いた文字表現の獲得
 - ひらがな・カタカナ・漢字(JIS第一・第二水準)・英字・記号を含む 計6,625文字を対象
- CLCNNアーキテクチャは [1] 準拠
 - 学習時は文書中から連続する128文字を切り出して入力
 - 評価時は128文字をスライドさせ



3. Experiments

- Wildcard率の変更実験
- 中国語に対する Image-based CLCNN with WTの性能確認実験 (5-fold cross validationで評価)

評価用データセット


- 青空文庫の著者推定
 - 104 作品, 著者 10 名
- Wikipediaタイトルのカテゴリ推定
 - 206,313 タイトル, 12 カテゴリ
- TED Talksのタグ推定
 - TED Talksの中国語訳(簡体字) 1,008 トークを対象
 - トークには複数タグが付与 -> 数が多かったカテゴリ2つを選択
 - Technology: 546トーク, Culture: 462トーク の2クラスを推定

青空文庫の著者推定の結果

Wildcard Ratio	0.0	0.1	0.2	0.3	0.4	0.5	0.6	Linear up	Linear down	Expo. up	Expo. down
Acc.	64.8	74.4	73.7	74.5	74.8	72.5	70.3	74.8	74.8	72.2	72.3

Wikipediaタイトルのカテゴリ推定の結果

Wildcard Ratio	0.0	0.1	0.2	0.3	0.4	0.5	0.6	Linear up	Linear down	Expo. up	Expo. down
Acc.	36.2	54.1	54.6	54.7	54.7	54.4	53.9	54.1	53.7	53.4	54.1



TED Talksのタグ推定の結果

Method	Acc.
CLCNN	80.6
CLCNN + WT (0.2)	81.6
ロジスティック回帰 with TF-IDF of character-level 2-gram	80.5

4. Discussion and Conclusion

- Wildcard trainingにおけるWildcard率について検討
 - Wildcard率を0.1~0.4に設定すると効果的.
- 他言語への Wildcard trainingの適用
 - 中国語は1文字の持つ意味が大きいと考えられるため, WTの効果は限定的であったと考えられる.
- Wildcard率以外の検討と今後の展望
 - 入力文字embeddingの平均ベクトルや零ベクトル以外で置き換える.

5. Reference

- [1] Shimada, Daiki, Ryunosuke Kotani, and Hitoshi Iyatomi. "Document classification through image-based character embedding and wildcard training." Big Data (Big Data), 2016 IEEE International Conference on. IEEE, 2016.
- [2] Rennie, Steven J., Vaibhava Goel, and Samuel Thomas. "Annealed dropout training of deep networks." Spoken Language Technology Workshop (SLT), 2014 IEEE. IEEE, 2014.