





Summary & Background



Method & Implementation


■ モデル π_θ の入出力とデザイン修正の定式化

- 入力: レンダリング画像 I ・各デザイン要素のメタ情報 E_0
- 出力: 修正対象の要素ID・編集種別・編集パラメータを含む JSON 形式編集アクション $A \rightarrow$ その適用後 E_1

$$A \sim \pi_\theta(\cdot | I, E_0) \quad E_1 = \text{Apply}(E_0, A)$$

■ 学習データと学習対象

- Crello データセット [Yamaguchi ICCV'23] を Ground Truth (GT) として人工的な摂動を加えて、修正前後ペアを作成
- モデルは摂動後のデザインから問題要素を特定・元の意図を保つ修正を学習



Results & Future Work

■ レイアウト修正・Phase 1 の結果

[†] OpenAI API の structured output
[‡] Structured output 不使用

Method	Model	JSON $\uparrow$	Prec. $\uparrow$	Rec. $\uparrow$	F1 $\uparrow$
Random 修正		N/A	0.130	0.118	0.124
Heuristic 修正		N/A	0.175	0.158	0.166
Zero-shot VLM	gpt-5-mini	[†] 1.000	0.162	0.422	0.234
	gpt-5	[†] 1.000	<u>0.194</u>	<u>0.541</u>	<u>0.287</u>
	Qwen3-VL	0.317	0.054	0.069	0.061
Ours	Qwen3-VL	[‡] 1.000	0.242	0.553	0.344

提案手法が現状ベストな結果

- ランダム予測・ヒューリスティックな予測方法よりも優位な結果
- フロンティアモデル (GPT-5) やベースとなっているモデル (Qwen) よりも優位
- 視覚エンコーダはチューニングするとよい

■ 結論と今後

“ズレた要素を予測” 依然としては難しい

- 比較手法として F1 は向上した一方で正常要素や関連要素も拾う場合があり
- 特権情報 (e.g., GT) を教師に見せつつ生徒の思考プロセスを学習させる On-policy 蒸留 [Agarwal+ ICRL'24] に注目

デザイン生成技術の発展: ポスター・広告への応用



- LLM / VLM を使うレイアウト生成の増加
HTML/SVG 形式での生成 [Lin+ NeurIPS'23; Seol+ ECCV'24 Tian+ arXiv'25]

ラスター画像生成は編集 ✕ ベクター・レイヤー生成へ

- レイヤーや要素を保った編集可能なベクター表現が重要に [Yamaguchi ICCV'21; Suzuki+ ICCV'25; Chen+ CVPR'25]

フロンティアモデルは生成に強いが、修復・編集は弱い

- VLM は細かな空間関係に弱さあり [Liu+ ACL'25]
- 生成能力と修復能力も別問題 [Jimenez+ ICLR'24; Xiao+ arXiv'25]

“デザイン修正” を診断の方策学習として定式化

- 正常デザインにズレ・重なり・スタイル崩れを加え問題要素と修正操作の教師データを作成
- 修正は一意ではないため、制約改善と最小編集を報酬として GRPO を応用 [Shao+ arXiv'24; DeepSeek-AI+ arXiv'25]

レイアウト修正とスタイル修正を段階的に学習するカリキュラム学習

■ 学習カリキュラム

- Phase1: 修正対象要素の特定** {"element_id": 1}
- Phase2: 要素 ID + 編集種別の予測 {"element_id": 1, "action": "move"}
- Phase3: 上記を含めパラメータ付き JSON 形式編集アクション

■ 編集アクション A に対する報酬設計 $R(A)$

$$R(A) = \lambda_{\text{json}} \cdot r_{\text{json}} + \lambda_{\text{cons}} \cdot (C(E_1) - C(E_0)) - \lambda_{\text{edit}} \cdot D(E_1, E_0) + \lambda_{\text{ref}} \cdot r_{\text{multi-ref}}$$

- JSON 形式の正しさ
- 制約スコア改善
- 最小編集コスト
- 複数参照解ボーナス

■ その他モデルパラメータ

- Qwen3-VL-32B-Thinking [Yang+ arXiv'25] をベース
 - 言語モデル側は LoRA-tuning [Hu+ ICLR'22]
 - 視覚エンコーダは full fine-tuning; 微細なレイアウト崩れに適応

■ 視覚エンコーダの学習の有無の比較

Variant	JSON $\uparrow$	Prec. $\uparrow$	Rec. $\uparrow$	F1 $\uparrow$
Vision Enc.	1.000	0.152	0.298	0.201
Vision Enc.	1.000	0.242	0.553	0.344

■ デザイン修正予測例



<think>
Quick scan: The "HOME" text (id 7) is oversized and overlaps the "MONEY" text (id 4), making it hard to read. This is a high-priority issue due to significant overlap hiding key text. The "from" text (id 6) is also partially occluded by the "MONEY" text, but the main problem is the "HOME" overlap. The design appears broken, not intentional.
</think>

```
```\njson\n[\n  {\n    \"element_id\": 7\n  }\n]\n```\n</im_end>
```

ズレている要素がなぜズレているかを思考しながら予測に至っている