

日本語の文字体系を考慮した文書分類モデルの提案

長澤 駿太, 北田 俊輔, 彌富 仁

{shunta.nagasawa.2u, shunsuke.kitada.8y} @stu.hosei.ac.jp




□ Background

Character Encoder(CE)


日本語の漢字や中国語は表意性を持つため、この性質を捉えることはこれら言語の意味理解において重要

→ **CNNを用いることで文字形状を捉えた文字表現を学習**



CEの問題点

- ひらがな・カタカナなど表音文字は表意性を持たないため、適切な文字表現を得ることが困難
- 似た形状でも意味が大きく異なる文字が存在
 - 「大」「犬」「太」「土」「士」



CEと既存の文字表現手法の2つの異なるembeddingを組み合わせることで
文字体系を考慮した文字表現の獲得を提案

□ Method

Fusion Embedding

文書データを入力とする分類、回帰タスクに対し
2つの異なるembeddingを組み合わせる手法の提案

● Attention^[1]



- それぞれのembeddingに対し重要度を算出

$$\mathbf{a} = \text{softmax}(\sigma(\mathbf{W}_{s2} \tanh(\mathbf{W}_{s1} [\mathbf{x}_{\text{look}}; \mathbf{x}_{\text{ce}}]^T)))$$

$$\mathbf{X} = (\mathbf{x}_{\text{look}}, \mathbf{x}_{\text{ce}})$$

$$\mathbf{v} = \mathbf{aX}$$

$\mathbf{W}_{s1}, \mathbf{W}_{s2}$: パラメータ $\mathbf{a}$: attentionベクトル




● Gate

- CEの出力からの重要度を算出

$$g = \sigma(\mathbf{W} \mathbf{x}_{\text{ce}}^T)$$

$$\mathbf{v} = g \odot \mathbf{x}_{\text{ce}} + (1 - g) \odot \mathbf{x}_{\text{look}}$$


$\mathbf{W}$: パラメータ g : 重要度



● Concatenate

- 2つのembeddingを連結


$$\mathbf{v} = [\mathbf{x}_{\text{look}}; \mathbf{x}_{\text{ce}}]$$



Model

Bi-LSTM 2層 + FC 1層で構成

- 過学習抑制のため wildcard training^[2]の導入
- CEをend-to-endで学習
- 最適化手法はAdam



□ Experiments

Dataset

楽天市場のレビューデータ

- ★1~★5までの5段階の分類タスク
- 学習用: 80万件, 評価用: 10万件
学習用データを7.5:2.5の割合で訓練用と開発用に分割
- 前処理として文字数を200文字で切り落とし or パディング

Loss Function

分類タスクと同時に回帰タスクを行うことでクラス間の
大小関係を考慮、評価にMAEを追加

$$\mathcal{L} = \text{CrossEntropy}(y^{(c)}, t) + \text{MSE}(y^{(r)}, t)$$

Result

手法	Accuracy[%] ↑	MAE ↓
Lookup only	56.61	0.578
Visual only	56.92	0.575
Attention	56.95	0.562
Gate	56.74	0.582
Concatnate	57.06	0.557

Fusion Embeddingを用いることで精度の向上を確認

Attention Map

Attention Map										
Lookup	0.28	0.33	0.29	0.64	0.57	0.38	0.29	0.33	0.30	0.30
Visual	0.72	0.67	0.71	0.36	0.43	0.62	0.71	0.67	0.70	0.70
	は	ぱ	ぱ	大	犬	太	猫	土	土	鮫

全体的にVisualの重みが大きくなっている

- CEの出力のベクトルの影響が強い
- lookupのベクトルの値が極端に小さい
→ CE側がより良い表現を得られてる

□ Conclusion & Future work

Conclusion

- 異なるembeddingを組み合わせる
Fusion Embeddingの提案
→ ベースラインと比べ、若干の精度向上を確認

Future Work

- 異なるembeddingを同時に学習する方法の模索
- 最適なパラメータ、アルゴリズムの検討

□ Reference

- [1] S. Moon, L. Neves, and V. Carvalho, "Multimodal Named Entity Recognition for Short Social Media Posts", Association for Computational Linguistics, pp: 852-860, 2018.
- [2] D. Shimada, R. Kotani, and H. Iyatomi, "Document classification through image-based character embedding and wildcard training," IEEE International Conference on Big Data, pp. 3922–3927, 2016.

